Víme, kdo co četl, ale chybí nákupy, data i žánry

Co obsahují data, která jste poslali

TABULKA	ATRIBUTY	ŘÁDKY
Books	ISBN, název, autor, rok, vydavatel, URL obálky	271 tis.
Ratings	uživatel, ISBN, hodnocení 0–10	1,15 mil.
Users	ID, lokalita, věk (40 % chybí)	279 tis.

Hodnocení / interakce	ano
Nákupy, ceny, objednávky	chybí
Data, návštěvy, kliky	chybí
Žánry, anotace, sklad	chybí

56 %
uživatelů má **jedinou** interakci; jen 22 % má 5+

62 %
hodnocení je **0**: interakce bez známky

4,4
prům. hodnocení nejčastější knihy (rozdávaný titul)

15
ISBN pro jednu knihu Harryho Pottera

Předpoklady a zacházení s vadnými daty

- **Jakákoli interakce = zájem**; hodnocení 1–4 zájem nejsou (1,7 % známek)
- **Jedna kniha = jedno dílo**: 270 tis. ISBN sloučeno do 227 tis. děl
- **Vyřazeno a spočítáno:** 10 % hodnocení bez metadat, vadná ISBN, 46 hromadných účtů
- **Nepoužito:** věk a lokalita. Slabý signál a citlivé kvůli GDPR

Můj pohled Tato hodnocení stačí na postavení a otestování enginu a už jsme to udělali. Nárůst prodejů neprokážou. Riziko PoC jsou data o objednávkách, ne algoritmus, proto je G1 prověří jako první.

Začneme jednoduše: „čtenáři této knihy četli také“, otestováno proti bestsellerům

PŘÍSTUP	NA TĚCHTO DATECH	NDCG@10	POKRYTÍ	ROLE
Popularita počet / vážená kvalitou	Funguje, ale stejný seznam pro všechny	0,019	0,1 %	baseline, cold start
Content-based vlastnosti knih	Jen název, autor, vydavatel: příliš málo	–	–	po PoC
Item-kNN (BM25) kolaborativní	Nejlepší pořadí, vysvětlitelné, levné	**0,066**	**77 %**	hlavní
ALS maticová faktorizace	Blízko, ale hlavně bestsellery	0,054	8,5 %	vyzyvatel
Hybrid	Potřebuje žánry a anotace	–	–	po PoC

Offline test na vašich hodnoceních: 15,6 tis. čtenářů × 29,4 tis. děl, u každého skryto 20 % knih. V PoC znovu na objednávkách. Podrobnosti: příloha A4.

Jak to funguje, jednou větou

Dvě knihy jsou si podobné, když je čtou stejní čtenáři. Velmi populární knihy a velmi aktivní čtenáře srážíme (BM25), aby megabestseller nebyl „podobný“ všemu. Podrobně: příloha A3.

Cold start, řešený podle situace

- **Nový návštěvník:** bestsellery vážené kvalitou
- **Viděl jednu knihu:** její podobné knihy
- **Nový titul:** teď stejný autor nebo série; obsahový model po PoC

Můj pohled — Za 30 MD raději dodám model, kterému byznys věří, než takový, který nikdo nevysvětlí. Složitost musí porazit baseline, jinak nezůstane.

Item-kNN s BM25, krok za krokem

1

Matice čtenář × kniha

15,6 tis. čtenářů × 29,4 tis. děl. Buňka je 1, pokud čtenář s knihou interagoval, s váhou až 3 za vysoké explicitní hodnocení.

2

Váhování BM25

Převzato z vyhledávačů: čtenář, který přečetl 1 000 knih, o každé řekne méně, a kniha, kterou četl každý, řekne méně o vkusu.

3

Podobnost kniha–kniha

Porovnáme vážené sloupce čtenářů dvou knih; ke každé knize necháme 200 nejpodobnějších (K vyladěno na validaci).

4

Doporučit + vysvětlit

Detail knihy: nejpodobnější knihy. Člověk: součet podobností přes jeho historii; kniha, která přispěla nejvíc, je důvod „protože jste četli“.

Příklad

Hobit → *Dvě věže*: obě četlo 111 čtenářů. Následují další Tolkienovy svazky, pak jiná fantasy.

Proč ne deep learning?

Velmi řídká data (hustota 0,1 %), žádné sekvence ani text k využití a rozpočet 30 MD. Neuronový model by stál víc, hůř by se vysvětloval a nic nenaznačuje, že by tu vyhrál.

Náklady na provoz

Trénink trvá sekundy na CPU notebooku. Výstupem je vyhledávací tabulka, takže servírování je jen čtení z key-value úložiště.

Kód: src/experiment.py, src/export_prototype.py · knihovna: implicit

Offline test na vašich hodnoceních: nastavení a celé výsledky

Nastavení

- **Data:** vyčištěné 5-core, 536 tis. interakcí
- **Split:** u každého čtenáře náhodně skryto 20 % knih (data nejsou)
- **Ladění:** na druhých skrytých 20 %, nikdy na testu
- **Otázka:** jsou skryté knihy v top 10 modelu?

Metriky lidsky

- **Hit rate@10:** podíl čtenářů s aspoň jedním zásahem
- **NDCG@10:** zásahy, víc oceněné nahoře
- **Pokrytí:** podíl katalogu, který se kdy doporučí

Na vašich datech přejdeme na časový split: trénink na minulosti, test na posledních týdnech.

MODEL	P@10	R@10	NDCG@10	HIT@10	POKRYTÍ
Bestsellery (počet)	0,010	0,020	0,019	8,1 %	0,1 %
Bestsellery (kvalita)	0,005	0,008	0,008	3,8 %	0,1 %
Item-kNN (cosine)	0,013	0,040	0,035	9,7 %	58,6 %
ALS	0,026	0,062	0,054	18,2 %	8,5 %
Item-kNN (BM25)	0,031	0,067	**0,066**	**19,2 %**	**76,5 %**

NDCG@10 podle velikosti historie

KNIH V HISTORII	4–9	10–49	50+
Čtenářů	8 220	5 688	1 734
Bestsellery (počet)	0,012	0,016	0,061
Item-kNN (BM25)	0,045	0,071	0,148

Model vítězí nejvíc tam, kde na tom nejvíc záleží: u čtenářů s krátkou historií (3,8× baseline).

Reprodukce: python src/prep.py · python src/experiment.py (GitHub repo)

Čtyři kontroly, každá těžší na oklamání než ta předchozí

1 · Data

Je vstup takový, jak si myslíme?

- Odsouhlasení součtů s vašimi finančními čísly
- Automatické kontroly: duplicity, úspěšnost joinů, odlehlé hodnoty, hromadné účty
- Unit testy každého kroku čištění

2 · Model, offline

Předpovídá, co lidé koupili příště?

- Trénink na minulosti, test na posledních týdnech objednávek
- NDCG, recall a hit rate @10, vždy proti baseline
- Pokrytí a novost, výsledky po segmentech zákazníků

3 · Lidé

Ukázal by to knihkupec?

- Slepý test: náš seznam vs. bestsellery, hodnotí vaši experti
- Kontrola varovných signálů: vyprodané, nevhodná věková skupina, duplicity

4 · Trh · po PoC

Prodává víc?

- A/B test na detailu knihy, provoz 50 / 50
- Tržba na návštěvu; CTR, přidání do košíku, AOV
- Pojistky: rychlost stránky, bounce rate. Délka podle výpočtu síly testu z vaší návštěvnosti

Pravidlo týmu: žádná metrika bez baseline a každé číslo jde zreprodukovat z Gitu jedním příkazem.

Architektura PoC: dávková, offline a reprodukovatelná, bez zásahu do živého e-shopu

1 · ZDROJE

Historie objednávek
export, 2–3 roky

Katalog
ISBN, autor, žánr, cena

Webové události
zobrazení, pokud jsou

Export hodnocení
máme, už analyzováno

2 · PŘÍPRAVA

Načtení a validace
počty řádků, schéma, úspěšnost joinů

Čištění
sloučení edic → díla, oprava textů, vyřazení hromadných účtů

Matice interakcí
zákazník × dílo, vážený signál

3 · MODEL A EVALUACE

Baseline
bestsellery, vážené kvalitou

Podobnost knih
hlavní model

ALS · vyzyvatel
+ obsahová podobnost pro nové tituly

Evaluační rámec
časový split, metriky, segmenty

4 · VÝSTUPY

Tabulky doporučení
top-20 pro knihu a zákazníka

Demo aplikace
procházení, srovnání, vysvětlení

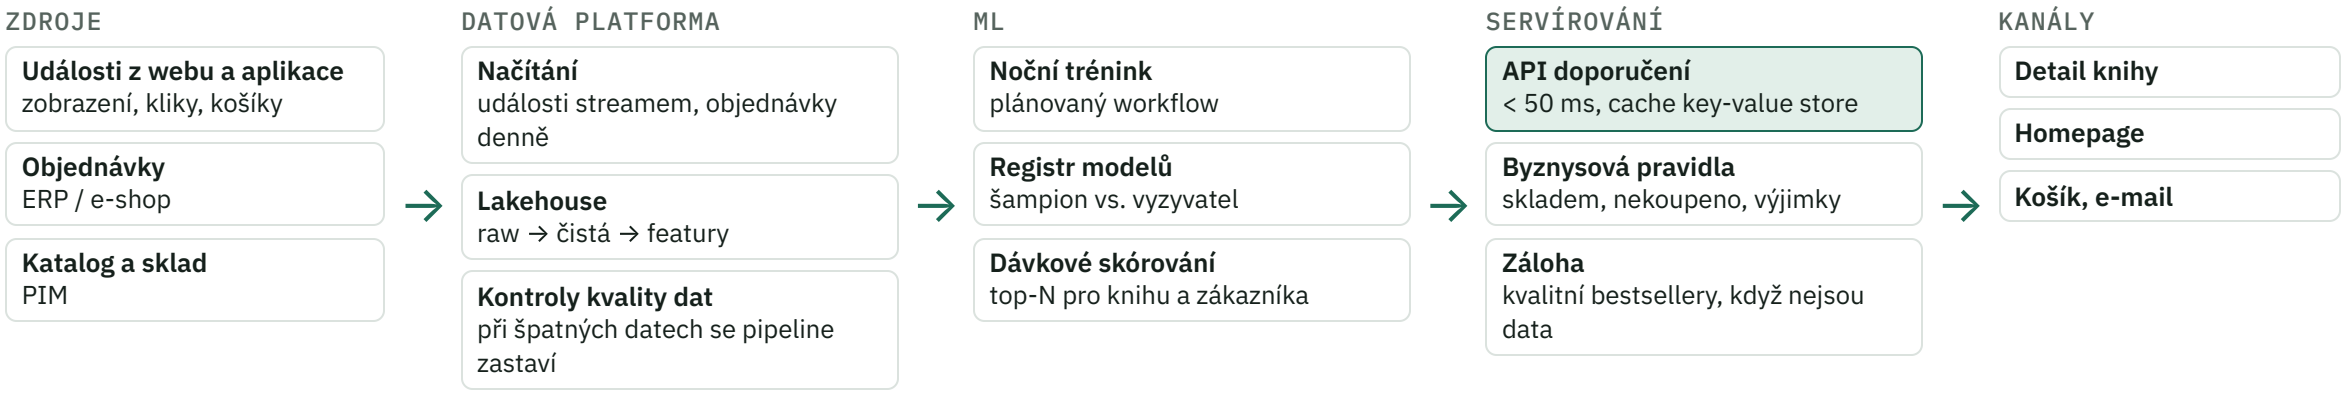
Evaluační report
+ slepý test expertů

Stack · Python (pandas, implicit, scikit-learn), Databricks nebo váš cloudový workspace, MLflow pro experimenty, Git.

Proč dávkově · Čtenářský vkus se mění pomalu. Noční seznamy stačí na prokázání hodnoty a real-time by přidal náklady dřív, než víme, že se vyplatí.

Data zůstávají u vás · Pracujeme ve vašem prostředí nebo v zabezpečeném workspace DataSentics podle DPA; ID zákazníků pseudonymizovaná.

V produkci: noční modely, rychlé API s pravidly a A/B test u každé změny



PoC vs. produkce

	POC · 30 MD	PRODUKCE
Data	jednorázové exporty	automatické denní feedy + události
Trénink	ručně, sledovaně	noční job, šampion vs. vyzyvatel
Servírování	tabulky + demo	API < 50 ms, pravidla, záloha
Důkaz	offline metriky + experti	A/B test, dashboard tržeb
Provoz	Git, MLflow	CI/CD, alerty driftu, vlastník, rollback
Ochrana dat	pseudonymizovaný výřez, DPA	kontrola souhlasu, retence, přístupy

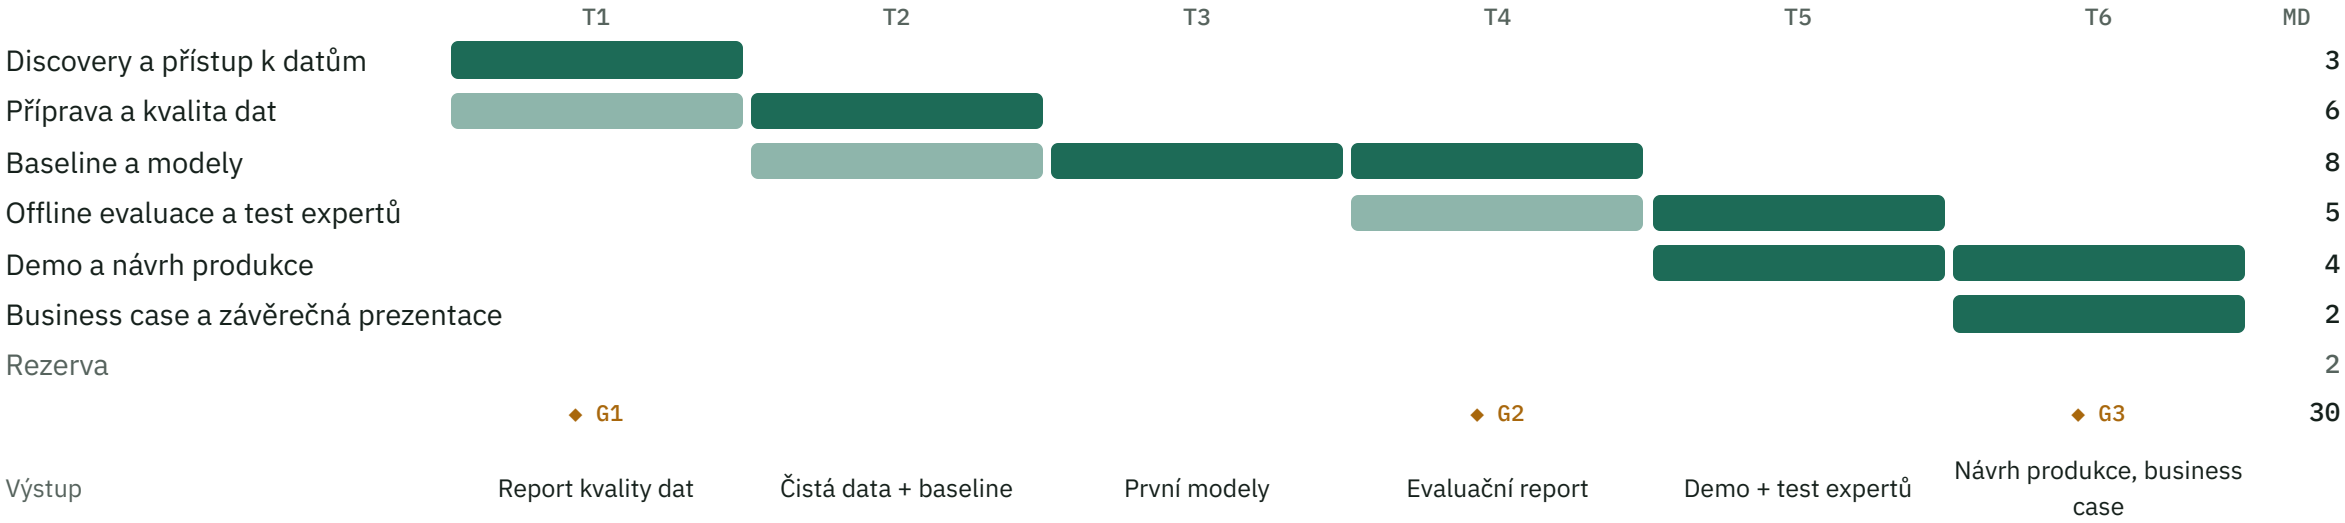
Napojení na váš e-shop

- A **Volání API** z e-shopu pro každou stránku: nejflexibilnější, potřebuje vývojáře
- B **Plug-in platformy** (např. Shopify, Magento, Shoptet) plněný našimi seznamy
- C **Noční souborový feed** do databáze e-shopu: nejjednodušší start, bez real-time

Kterou zvolit, závisí na vašich systémech: platforma e-shopu, objednávkový systém / ERP, katalog (PIM), webová analytika, nástroj na newsletter. Zmapujeme je v T1 a vybereme v T5.

Můj pohled: stejný kód jako v PoC, jen naplánovaný a monitorovaný. Real-time featury přidáme, jen pokud pilot ukáže, že se vyplatí.

Šest týdnů, tři rozhodovací body a jasné závislosti na vaší straně



Milníky a rozhodovací body

G1	**Konec T1 · jsou data dost dobrá?** Pokud ne, upravíme rozsah, místo abychom pálili dny
G2	**Konec T4 · poráží model baseline** o dohodnutý rozdíl?
G3	**Konec T6 · go / no-go** pro živý A/B pilot

Závislosti na vaší straně

- **Export dat + DPA do 3. dne**, jinak se posune celý plán
- **2 experti na sortiment**: workshop v T1, slepý test v T5
- **Vedoucí webu / IT** pro návrh integrace v T5
- **Sponzor** na pátečním steeringu a u každého gate

2 MD rezervy drží vedoucí řešení, uvolňují se jen přes steering

Co za 30 MD dostanete, co ne a co přijde potom

V PoC

- **Detail knihy:** „čtenářům se líbilo také“ pro každého návštěvníka
- **Vybráno pro vás:** pro zákazníky s historií
- **Záloha:** bestsellery vážené kvalitou
- Natrénováno a ověřeno na **vašich** objednávkách a katalogu

Výstupy

D1	Report kvality dat	T1
D2	Čistá data + kód pipeline	T2
D3	Modely + evaluační report	T4
D4	Demo + slepý test expertů	T5
D5	Návrh produkce, náklady, business case, plán A/B	T6

Mimo 30 MD a proč

- **Živá integrace** do e-shopu: potřebuje váš webový tým; dodáme návrh a kontrakt API
- **Spuštění A/B testu:** potřebuje integraci a 4–6 týdnů provozu
- **Doporučení v reálném čase:** na prokázání hodnoty stačí noční seznamy
- Umístění v **košíku a e-mailu**
- **Engine byznysových pravidel** (sklad, marže): navržený, ne postavený
- **Obohacení katalogu** (žánry, anotace)

Po úspěšném PoC

1. **A/B pilot** na detailu knihy
2. **Byznysová pravidla:** sklad, marže, věk, výjimky
3. **Hybridní model:** žánry, anotace, textové embeddingy pro nové tituly
4. **Cross-sell v košíku** a osobní newsletter
5. Tipy podle **aktuální návštěvy** pro anonymní návštěvníky

Seřazeno podle očekávané hodnoty vůči úsilí; každý krok je samostatné rozhodnutí.

Provoz a údržba

Přetrénování a monitoring běží automaticky; určený vlastník měsíčně kontroluje kvalitu a čtvrtletně model přelaďuje. Náklady a pracnost odhadneme v D5.

Malý tým DataSentics, správní lidé na vaší straně a týdenní rytmus

DataSentics · 30 MD

AI Consultant / Architect já · vedoucí řešení Rozsah, architektura, kontakt s klientem, rozhodnutí	7
Data Scientist Modely, evaluace, test expertů	12
Data Engineer Přístupy, načtení, čištění, kvalita	6
ML Engineer Demo aplikace, návrh produkce, náklady	5

Online knihkupectví

Sponzor Vlastní cíl, rozhoduje v gate	~2 h/týd.
Product owner Priority, přebírá výstupy	½ dne/týd.
Vlastník dat / IT Exporty, přístupy, bezpečnost	T1
Experti na sortiment (2) Byznysový kontext, slepý test	T1, T5
Vedoucí webu + DPO Cesta integrace, GDPR	ad hoc

Jak to řídím

- **Týdenní smyčka:** v pondělí plán s PO, denní stand-up, v pátek demo + 30min steering
- **Rozpočet na očích:** čerpání MD vs. plán každý pátek
- **Jeden vlastník** a definice hotového u každého výstupu
- **Log rozhodnutí a rizik** sdílený s vámi; změny jdou přes steering
- **Kvalita:** code review, sledované experimenty, žádná metrika bez baseline

Rizika: příloha A11.

Co se může pokazit a co se od vás potřebujeme dozvědět

Otevřené otázky pro vás

OTÁZKA	PROČ NA TOM ZÁLEŽÍ
Kolik let objednávek, s ID zákazníka, datem, cenou?	Bez dat nejde otestovat „co koupili příště“
Jaký podíl návštěv a objednávek je přihlášený?	Rozhoduje, kolik lidí osobní tipy osloví
Co obsahuje záznam v katalogu: žánr, anotace, sklad?	Závisí na tom nové tituly a byznysová pravidla
Jaká platforma e-shopu a kdo vlastní integraci?	Určuje cestu do produkce a její cenu
Pokrývá souhlas personalizaci? Mohou data opustit váš cloud?	Kde pracujeme a co smíme použít
Které KPI je nejdůležitější a jaký nárůst investici vrátí?	Určuje laťku úspěchu a délku pilotu
Pravidla, která musíme respektovat: vlastní tituly, dohody s vydavateli, věk?	Tvaruje vrstvu byznysových pravidel

Hlavní rizika

RIZIKO	OPATŘENÍ
vysoké Přístup k datům se zpozdí	Mezitím stavíme na exportu hodnocení; G1
vysoké Offline zisk neplatí online	A/B pilot s pojistkami před nasazením
střední Historie objednávek je slabá nebo chaotická	V G1 zúžit na detail knihy
střední Chybí kapacita na integraci	Vlastníka určit dnes; kontrakt API v T5
střední Rozšiřování rozsahu	Změny jen přes steering; backlog na později

Omezení, která říkáme otevřeně: hodnocení neprokážou prodeje; bez dat používá offline test náhodný split, který metriky přikrášluje; metadata nestačí na obsahové modely.

PoC prokáže, že engine stojí za živý test. Živý test prokáže, že prodává

Strom tržeb

Tržby = návštěvy × konverzní poměr × průměrná hodnota objednávky

PÁKA	JAK NA NI DOPORUČENÍ PŮSOBÍ	KPI
Objevování	Zákazník najde další relevantní knihu, místo aby odešel	CTR
Konverze	Více návštěv skončí nákupem	CR
Košík	O knihu víc v objednávce (série, stejný autor)	AOV
Katalog	Prodeje se rozloží i mimo top bestsellery	Coverage

Hlavní KPI pilotu: **tržba na návštěvu**. CTR a přidání do košíku vysvětlí, proč se pohnula.

Kritéria úspěchu PoC

Návrh k odsouhlasení dnes

- Model poráží nejlepší baseline na vašich odložených objednávkách, **průkazně** (95% CI) a o **≥ 20 %** v NDCG@10
- **≥ 70 %** vzorových seznamů označí vaši odborníci na sortiment jako „tohle bych ukázal“
- S IT je odsouhlasená cesta integrace a provozní náklady
- Business case postavený na vaší návštěvnosti a konverzích

Proč 20 %: záměrně konzervativně (na vašich hodnoceních +250 %). Konečnou laťku ověříme proti návratnosti v business case.

Offline ≠ online. PoC ukáže, že je model dobrý. Že prodává, ukáže až živý A/B test.

Metriky nestačí: knihkupec musí nad seznamy přikývnout

Čtenář si prohlíží

The Hobbit · Tolkien

1. The Two Towers · Tolkien
2. The Return of the King · Tolkien
3. The Fellowship of the Ring · Tolkien
4. The Lord of the Rings · Tolkien
5. The Last Battle · C. S. Lewis

Nejdřív série, pak příbuzná fantasy klasika.

Čtenář si prohlíží

Bridget Jones's Diary · Fielding

1. Bridget Jones: The Edge of Reason · Fielding
2. Last Chance Saloon · Marian Keyes
3. Jemima J · Jane Green
4. Smart vs. Pretty · Valerie Frankel
5. Behind the Scenes at the Museum · Kate Atkinson

Žánr se naučil, aniž by o žánrech měl jakákoli data.

Kde to selhává

The Da Vinci Code · Dan Brown

1. Angels & Demons · Dan Brown
2. The Time Traveler's Wife · Niffenegger
3. All He Ever Wanted · Anita Shreve
4. Stupid White Men · Michael Moore
5. White Death · Clive Cussler

Megabestsellery čte každý, takže jejich sousedé jsou zašuměné. Řešení: žánrová metadata a byznysová pravidla.

V PoC tyto seznamy dostanou vaši odborníci na sortiment jako slepý test: náš seznam vs. bestsellery, bez označení. Jejich verdikt je kritérium úspěchu.

Skutečný výstup modelu item-kNN na vašich hodnoceních

Problémy, které jsme v datech našli, a jak řešíme každý z nich

PROBLÉM	ROZSAH	CO DĚLÁME
Hodnocení knih, které nejsou v katalogu	10 % hodnocení	Vyřazeno a spočítáno
Vadná ISBN	10 tis. hodnocení	Vyřazeno
Jedna kniha pod více ISBN (edice)	270 tis. → 227 tis. děl	Sloučeno do děl
„0“ znamená interakci, ne špatnou známku	62 % hodnocení	Bráno jako zájem
Nelíbilo se (známky 1–4)	1,7 % známek	Nepočítáme jako zájem
Hromadné účty (nahraný katalog)	46 účtů, 86 tis. řádků	Odstraněno
Rozdávaná kniha vede žebříček popularity	1 titul, 2,5 tis. interakcí	Bestsellery vážené kvalitou

PROBLÉM	ROZSAH	CO DĚLÁME
Extrémní řídkost, jednorázoví čtenáři	56 % jedna kniha; 174 tis. uživatelů žádná	Trénink na 5+ interakcích; tipy na detailu a záloha pro ostatní
Posunuté sloupce, rok 0 nebo v budoucnosti (2050)	3 + 4,6 tis. + 23 knih	Rok nastaven jako neznámý; model ho nepoužívá
Věk chybí nebo je nesmyslný (0, 244)	40 % chybí	Demografie nepoužita (slabá, GDPR)
Chybí data, objednávky, ceny, kliky, sklad	celý export	Žádáme od vás; mezitím náhodný testovací split
Chybí žánry a anotace; jen první autor	celý katalog	Bez obsahového modelu v PoC; obohatit potom
Prázdné nebo staré odkazy na obálky	část knih	Vykreslená náhradní obálka
Rozbitá diakritika a HTML v názvech	2–3 % názvů	Opraveno

Princip: neopravujeme nic, co neumíme ověřit, a vše vyřazené spočítáme a vykážeme. Na vašich objednávkách poběží stejné kontroly automaticky a podpoří rozhodnutí v týdnu 1.

Celá analýza: docs/eda v GitHub repu